

概率论与数理统计学习笔记

Raisetsu41

厦门大学 · 邹至庄经济研究院 · 2026 秋

更新至 Chapter 1.5

按 Casella and Berger, *Statistical Inference*, 2nd ed. 与 2026 秋课堂讲义整理。

目录

1	概率论基础	3
1.1	Set Theory (集合论)	3
1.2	Basics of Probability Theory (概率论基础)	4
1.3	Conditional Probability and Independence (条件概率与独立性)	6
1.4	Random Variables (随机变量)	11
1.5	Distribution Functions (分布函数)	12

1 概率论基础

1.1 Set Theory (集合论)

1.1.1 From random experiment to probability model (从随机试验到概率模型)

A random experiment has well-defined possible outcomes, but the realized outcome is uncertain before the experiment.

random experiment $\rightarrow$ sample space $S \rightarrow$ events $A \rightarrow$ probabilities $P(A)$

(随机试验 $\rightarrow$ 样本空间 $\rightarrow$ 事件 $\rightarrow$ 概率)

1.1.2 Sample space and events (样本空间与事件)

- **Sample space** S (样本空间): the set of all possible basic outcomes; finite (有限), countably infinite (可数无限), or uncountable (不可数).
- **Countable** (可数): can be placed in one-to-one correspondence with a subset of the integers.
- **Event** (事件): any subset $A \subseteq S$; A occurs iff the realized outcome $\in A$.
- $\emptyset$: the impossible event (不可能事件).
- $A \subseteq B \iff (x \in A \Rightarrow x \in B)$; $A = B \iff A \subseteq B$ and $B \subseteq A$. Prove set equality by double inclusion (双向包含).

1.1.3 Set operations and algebra of sets (集合运算与代数性质)

$$A \cup B = \{x : x \in A \text{ or } x \in B\}, \quad A \cap B = \{x : x \in A \text{ and } x \in B\},$$

$$A^c = \{x \in S : x \notin A\}.$$

- Commutative, associative, distributive laws all hold;
- De Morgan's laws: $(A \cup B)^c = A^c \cap B^c$, $(A \cap B)^c = A^c \cup B^c$;
- Generalized De Morgan for countable unions/intersections:

$$\left(\bigcup_i A_i \right)^c = \bigcap_i A_i^c, \quad \left(\bigcap_i A_i \right)^c = \bigcup_i A_i^c.$$

- $\bigcup_{i=1}^{\infty} A_i$: belongs to at least one A_i ; $\bigcap_{i=1}^{\infty} A_i$: belongs to every A_i .

1.1.4 Partitions (分割)

- **Mutually exclusive** (pairwise disjoint) (两两互斥): $A_i \cap A_j = \emptyset$ for $i \neq j$;
- **Collectively exhaustive** (穷举): $\bigcup_i A_i = S$;
- **Partition** (分割): pairwise disjoint and collectively exhaustive. Central for the law of total probability and Bayes' rule.

1.2 Basics of Probability Theory (概率论基础)

1.2.1 σ -algebra (σ -代数)

A collection $\mathcal{B}$ of subsets of S is a σ -algebra if:

1. $\emptyset \in \mathcal{B}$;
2. $A \in \mathcal{B} \Rightarrow A^c \in \mathcal{B}$;
3. $A_1, A_2, \dots \in \mathcal{B} \Rightarrow \bigcup_{i=1}^{\infty} A_i \in \mathcal{B}$.

By De Morgan's laws, a σ -algebra is also closed under countable intersections. The power set 2^S and the trivial family $\{\emptyset, S\}$ are both σ -algebras.

1.2.2 Probability function and axioms (概率函数与公理)

A complete probability model is $(S, \mathcal{B}, P)$, with $P : \mathcal{B} \rightarrow [0, 1]$:

1. Nonnegativity (非负性) : $P(A) \geq 0$;
2. Normalization (规范性) : $P(S) = 1$;
3. Countable additivity (可数可加性) : for pairwise disjoint $A_1, A_2, \dots$,

$$P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i).$$

Key point: the axioms regulate how probabilities behave; they do not determine which probability model fits a given experiment (公理只约束概率运算, 不决定具体模型; 那是建模假设).

1.2.3 Consequences of the axioms (公理推论)

$$P(\emptyset) = 0, \quad 0 \leq P(A) \leq 1, \quad P(A^c) = 1 - P(A),$$

$$A \subseteq B \Rightarrow P(A) \leq P(B) \quad (\text{monotonicity}).$$

Two-event identities (两事件公式) :

$$P(B \cap A^c) = P(B) - P(A \cap B),$$

$$P(A \cup B) = P(A) + P(B) - P(A \cap B).$$

1.2.4 Partition identity and inequalities (分割公式与不等式)

- If $\{C_i\}$ is a partition of S , then (全概率结构) :

$$P(A) = \sum_i P(A \cap C_i).$$

- **Boole's inequality:**

$$P\left(\bigcup_i A_i\right) \leq \sum_i P(A_i).$$

- **Bonferroni lower bound** (via Boole on complements):

$$P\left(\bigcap_{i=1}^n A_i\right) \geq \sum_{i=1}^n P(A_i) - (n-1).$$

Two-event case: $P(A \cap B) \geq P(A) + P(B) - 1$.

1.2.5 Constructing a probability on a countable space (可数样本空间上构造概率)

Let $S = \{s_1, s_2, \dots\}$ be finite or countable. If $p_i \geq 0$ and $\sum_i p_i = 1$, then

$$P(A) = \sum_{i: s_i \in A} p_i$$

defines a probability function: assign probability mass p_i to each outcome and sum over the event.

1.2.6 Counting (计数)

- Multiplication principle (分步计数原理): k successive tasks with $n_1, \dots, n_k$ choices give $n_1 n_2 \cdots n_k$ ways.
- Factorial (阶乘): $n! = n(n-1) \cdots 1$, with $0! = 1$.

Sampling r objects from n :

Sampling	Ordered	Unordered
Without replacement (不放回)	$\frac{n!}{(n-r)!}$	$\binom{n}{r} = \frac{n!}{r!(n-r)!}$
With replacement (放回)	n^r	$\binom{n+r-1}{r}$

- Stars and bars (隔板法): arrange r stars and $n-1$ bars, then choose r positions for the stars.
- Multinomial coefficient (多重集排列): with k positions and values repeated $k_1, \dots, k_m$ times,

$$\frac{k!}{k_1! k_2! \cdots k_m!}.$$

1.2.7 Equally likely outcomes (等可能模型)

If the finite sample space has N equally likely outcomes,

$$P(A) = \frac{|A|}{|S|}.$$

Warning: valid only when the elementary outcomes are truly equally likely. Probabilities must follow the actual sampling mechanism; unordered outcomes are not automatically equally likely (不能为了方便把无序结果当作等可能).

1.3 Conditional Probability and Independence (条件概率与独立性)

1.3.1 Conditional Probability (条件概率)

Definition

对事件 A, B , 若 $P(B) > 0$, 则在 B 已发生的条件下, A 的条件概率为

$$P(A | B) = \frac{P(A \cap B)}{P(B)}.$$

获知 B 已发生后, 新的有效样本空间被限制到 B ; $P(A | B)$ 衡量 B 中同时属于 A 的概率质量占比。

1.3.2 Multiplication rule (乘法公式)

由定义直接得到

$$P(A \cap B) = P(A | B)P(B) = P(B | A)P(A).$$

对 $A_1, \dots, A_n$ 反复使用乘法公式, 可得 **chain rule**:

$$P\left(\bigcap_{i=1}^n A_i\right) = P(A_1) \prod_{i=2}^n P\left(A_i \mid \bigcap_{j=1}^{i-1} A_j\right),$$

前提是式中的条件概率均有定义。

1.3.3 Example: 连续抽到四张 A

一副 52 张的标准扑克牌不放回抽取, 前四张全是 A 的概率为

$$P(\text{first four cards are aces}) = \frac{4}{52} \cdot \frac{3}{51} \cdot \frac{2}{50} \cdot \frac{1}{49} = \frac{1}{\binom{52}{4}}.$$

每次抽牌都会改变下一次的条件样本空间, 因此各因子的分子、分母依次减少。

1.3.4 Example: 不放回抽球

盒中有 r 个红球和 b 个蓝球。连续不放回抽取两个球, 令

$$A = \{\text{first ball is red}\}, \quad B = \{\text{second ball is blue}\}.$$

则

$$P(A) = \frac{r}{r+b}, \quad P(B | A) = \frac{b}{r+b-1},$$

所以

$$P(A \cap B) = \frac{r}{r+b} \cdot \frac{b}{r+b-1}.$$

1.3.5 Law of Total Probability (全概率公式)

若 $A_1, A_2, \dots$ 构成样本空间 S 的一个 partition, 即两两互斥且并集为 S , 则对任意事件 B ,

$$P(B) = \sum_i P(B \cap A_i) = \sum_i P(B | A_i)P(A_i).$$

它把事件 B 按照所有可能来源 A_i 拆开, 再将各路径的概率相加。

1.3.6 Example: 三个组别

若 $P(B_i) = 1/3$, 且 $P(A | B_i) = i/6$, $i = 1, 2, 3$, 则

$$P(A) = \sum_{i=1}^3 P(A | B_i)P(B_i) = \frac{1}{3} \left(\frac{1}{6} + \frac{2}{6} + \frac{3}{6} \right) = \frac{1}{3}.$$

1.3.7 Bayes' Rule (贝叶斯公式)

若 $A_1, A_2, \dots$ 构成 partition 且 $P(B) > 0$, 则

$$P(A_i | B) = \frac{P(B | A_i)P(A_i)}{\sum_j P(B | A_j)P(A_j)}.$$

Interpretation

Bayes' rule 把条件方向从 $P(B | A_i)$ 反转为 $P(A_i | B)$:

$$\text{posterior} \propto \text{likelihood} \times \text{prior}.$$

分母是由全概率公式得到的 $P(B)$, 负责把各个未标准化权重归一化。

1.3.8 Example: 汽车保险风险分类

客户被分为高风险 H 、中风险 M 和低风险 L :

$$P(H) = 0.25, \quad P(M) = 0.25, \quad P(L) = 0.50,$$

一年内至少发生一次事故的条件概率为

$$P(A | H) = 0.25, \quad P(A | M) = 0.16, \quad P(A | L) = 0.10.$$

已知某客户发生事故, 则其属于高风险客户的概率为

$$\begin{aligned} P(H | A) &= \frac{P(A | H)P(H)}{P(A | H)P(H) + P(A | M)P(M) + P(A | L)P(L)} \\ &= \frac{0.25 \times 0.25}{0.25 \times 0.25 + 0.16 \times 0.25 + 0.10 \times 0.50} \\ &\approx 0.410. \end{aligned}$$

观察到事故后, 高风险类型的概率从 prior 0.25 更新到 posterior 0.410。

1.3.9 Example: 色盲问题

设总体中男性人数与女性人数之比为 $r : 1$, 则

$$P(M) = \frac{r}{1+r}, \quad P(W) = \frac{1}{1+r}.$$

若色盲事件为 D , 且

$$P(D | M) = p, \quad P(D | W) = p^2,$$

则随机选出的色盲者为男性的概率为

$$P(M | D) = \frac{p \frac{r}{1+r}}{p \frac{r}{1+r} + p^2 \frac{1}{1+r}} = \frac{r}{r+p}.$$

1.3.10 Monty Hall Problem (三门问题)

奖品等概率地藏在帘子 A, B, C 后。先选择 A , 主持人知道奖品位置, 并在另外两扇帘子中打开一扇空帘; 假设他打开了 B 。记

$$B^* = \{\text{host opens curtain } B \text{ and it is empty}\}.$$

主持人的行为规则意味着

$$P(B^* | A) = \frac{1}{2}, \quad P(B^* | B) = 0, \quad P(B^* | C) = 1.$$

由 Bayes' rule,

$$P(A | B^*) = \frac{\frac{1}{2} \cdot \frac{1}{3}}{\frac{1}{2} \cdot \frac{1}{3} + 0 \cdot \frac{1}{3} + 1 \cdot \frac{1}{3}} = \frac{1}{3},$$

$$P(C | B^*) = \frac{2}{3}.$$

Conclusion

换到 C 的获奖概率为 $2/3$, 高于坚持选择 A 的 $1/3$ 。这个结论依赖主持人“必定打开未选择的空帘, 并在有两扇空帘可选时等概率选择”的行为规则。

1.3.11 Independence (独立性)

Definition

事件 A 与 B 独立, 当且仅当

$$P(A \cap B) = P(A)P(B).$$

若 $P(B) > 0$, 则等价地有

$$P(A | B) = P(A),$$

即得知 B 发生不会改变 A 的概率。

1.3.12 Independence vs. disjointness (独立与互斥)

二者含义不同:

- **Disjointness:** $A \cap B = \emptyset$, 两个事件不能同时发生;
- **Independence:** 一个事件是否发生不提供关于另一个事件的信息。

若 A, B 互斥且 $P(A) > 0, P(B) > 0$, 则

$$P(A \cap B) = 0 < P(A)P(B),$$

所以它们不可能独立。只有当至少一个事件概率为 0 时, 互斥与独立才可能同时成立。

1.3.13 Example: 四次掷骰至少出现一次 6

独立掷一枚公平骰子四次。使用 complement rule,

$$\begin{aligned} P(\text{at least one six}) &= 1 - P(\text{no six}) \\ &= 1 - \left(\frac{5}{6}\right)^4 \\ &= \frac{671}{1296} \approx 0.518. \end{aligned}$$

更一般地, 若 $A_1, \dots, A_n$ 相互独立, 则其补事件也相互独立, 从而

$$P\left(\bigcup_{i=1}^n A_i\right) = 1 - P\left(\bigcap_{i=1}^n A_i^c\right) = 1 - \prod_{i=1}^n (1 - P(A_i)).$$

若 $P(A_i) = p$, 则

$$P\left(\bigcup_{i=1}^n A_i\right) = 1 - (1 - p)^n.$$

1.3.14 Review

1. **Conditional probability** 是在已知信息下重新校准概率模型。
2. **Multiplication rule** 计算一条联合路径; **total probability** 汇总所有互斥路径。
3. **Bayes' rule** 用观测证据把 prior 更新为 posterior。
4. **Independence** 表示信息不改变概率, 不能与“互斥”混淆。

1.3.15 Independence and complements (独立性与补事件)

Theorem

若 A 与 B 独立, 则以下三对事件也分别独立:

$$(A, B^c), \quad (A^c, B), \quad (A^c, B^c).$$

例如, 利用 $A = (A \cap B) \cup (A \cap B^c)$ 这一互斥分解,

$$\begin{aligned}
 P(A \cap B^c) &= P(A) - P(A \cap B) \\
 &= P(A) - P(A)P(B) \\
 &= P(A)[1 - P(B)] \\
 &= P(A)P(B^c).
 \end{aligned}$$

其余两种情形可用相同方法证明。因此，独立事件的任意补集组合仍保持独立。

1.3.16 Pairwise vs. mutual independence (两两独立与相互独立)

当事件数量不少于三个时，**pairwise independence** 不足以推出 **mutual independence**。

三个事件两两独立只要求

$$P(A \cap B) = P(A)P(B), \quad P(A \cap C) = P(A)P(C), \quad P(B \cap C) = P(B)P(C),$$

但不保证

$$P(A \cap B \cap C) = P(A)P(B)P(C).$$

Definition

事件 $A_1, \dots, A_n$ 相互独立，是指对任意子集 $\{i_1, \dots, i_k\} \subseteq \{1, \dots, n\}$ ，都有

$$P\left(\bigcap_{j=1}^k A_{i_j}\right) = \prod_{j=1}^k P(A_{i_j}).$$

Mutual independence 要求所有规模至少为 2 的子事件组都满足乘法关系；只检查每一对事件并不充分。

1.3.17 Example: 两两独立但不相互独立

设

$$S = \{a, b, c, d\},$$

四个结果等可能，并定义

$$A_1 = \{a, b\}, \quad A_2 = \{b, c\}, \quad A_3 = \{a, c\}.$$

每个事件的概率均为 $1/2$ ，任意两个事件的交集均只含一个结果，因此

$$P(A_i \cap A_j) = \frac{1}{4} = \frac{1}{2} \cdot \frac{1}{2} = P(A_i)P(A_j), \quad i \neq j.$$

所以三个事件两两独立。然而

$$A_1 \cap A_2 \cap A_3 = \emptyset,$$

从而

$$P(A_1 \cap A_2 \cap A_3) = 0 \neq \frac{1}{8} = P(A_1)P(A_2)P(A_3).$$

故它们并不相互独立。

1.3.18 Quiz check (课堂练习核对)

1. 盒中有 4 个红球、6 个蓝球，不放回抽取两个球：

$$P(\text{first red, second blue}) = \frac{4}{10} \cdot \frac{6}{9} = \frac{4}{15}.$$

2. 保险分类例中，

$$P(A) = 0.25(0.25) + 0.16(0.25) + 0.10(0.50) = 0.1525,$$

$$P(H | A) = \frac{0.25(0.25)}{0.1525} = \frac{25}{61} \approx 0.410.$$

3. 上述 A_1, A_2, A_3 的每个两两交集概率为 $1/4$ ，但三者交集概率为 0，因此两两独立而不相互独立。

1.4 Random Variables (随机变量)

Definition

随机变量 X 是从样本空间到实数集的函数：

$$X : S \longrightarrow \mathbb{R}.$$

X 的所有可能取值构成其值域，通常记为 $\mathcal{X}$ 。随机变量并不是“随机变化的数”，而是先把每个原始结果 $s \in S$ 映射为数值 $X(s)$ ；随机性来自试验结果 s 的不确定性。

$$s \in S \xrightarrow{X} X(s) \in \mathbb{R}.$$

1.4.1 Examples (随机变量示例)

Random experiment	Random variable
掷两枚骰子	$X =$ 两个点数之和
抛硬币 25 次	$X =$ 正面出现次数
测量作物反应	$X =$ 单位面积产量
抽样调查 50 位选民	$X =$ 支持某提案的人数

随机变量可以把复杂的原始结果压缩为当前分析所关心的 numerical summary。

1.4.2 Induced probabilities (随机变量诱导的概率)

给定 $X: S \rightarrow \mathcal{X}$, 样本空间 S 上的概率会诱导出 X 取值上的概率。对 $x \in \mathcal{X}$,

$$P(X = x) = P(\{s \in S : X(s) = x\}).$$

更一般地, 对 $A \subseteq \mathcal{X}$,

$$P(X \in A) = P(\{s \in S : X(s) \in A\}).$$

右侧集合是 A 在映射 X 下的原像。因此, 对随机变量事件求概率, 本质上仍然是在样本空间 S 上求概率。

Notation

- 大写字母 X, Y, Z 表示随机变量;
- 小写字母 x, y, z 表示随机变量的可能取值或实现值。

1.4.3 Example: 三次抛硬币

公平硬币独立抛三次, 令 X 为正面次数。样本空间为

$$S = \{HHH, HHT, HTH, THH, HTT, THT, TTH, TTT\}.$$

X 的概率分布为

x	0	1	2	3
$P(X = x)$	1/8	3/8	3/8	1/8

因此

$$P(0 \leq X \leq 1) = P(X = 0) + P(X = 1) = \frac{4}{8},$$

而

$$P(0 \leq X < 1) = P(X = 0) = \frac{1}{8}.$$

对离散型随机变量, 把 $\leq$ 改成 $<$ 可能改变事件本身, 不能忽略端点。

1.5 Distribution Functions (分布函数)

1.5.1 Cumulative distribution function (累积分布函数)

Definition

随机变量 X 的 cumulative distribution function (CDF) 定义为

$$F_X(x) = P(X \leq x), \quad x \in \mathbb{R}.$$

CDF 在所有实数 x 上都有定义, 而不只是在 X 的值域 $\mathcal{X}$ 上定义。若 $a < b$, 则

$$P(a < X \leq b) = F_X(b) - F_X(a).$$

1.5.2 Example: 三次抛硬币的 CDF

对正面次数 X ,

$$F_X(x) = \begin{cases} 0, & x < 0, \\ \frac{1}{8}, & 0 \leq x < 1, \\ \frac{3}{8}, & 1 \leq x < 2, \\ \frac{7}{8}, & 2 \leq x < 3, \\ 1, & x \geq 3. \end{cases}$$

这是一个阶梯函数。每个取值点 x_0 处的跳跃大小等于该点的概率质量:

$$F_X(x_0) - F_X(x_0^-) = P(X = x_0),$$

其中

$$F_X(x_0^-) = \lim_{x \uparrow x_0} F_X(x).$$

CDF 在跳跃点取跳跃后的函数值, 因此是 **right-continuous** (右连续) 的。

1.5.3 Example: 命中点到圆心的距离

射击命中半径为 R 的圆形靶, 且命中点在靶面上按面积均匀分布。令 X 为命中点到圆心的距离。

当 $0 \leq x \leq R$ 时, 事件 $\{X \leq x\}$ 对应半径为 x 的内圆, 因此

$$F_X(x) = \frac{\pi x^2}{\pi R^2} = \frac{x^2}{R^2}.$$

完整的 CDF 为

$$F_X(x) = \begin{cases} 0, & x < 0, \\ \frac{x^2}{R^2}, & 0 \leq x \leq R, \\ 1, & x > R. \end{cases}$$

Key point

“在圆面上按面积均匀” 不等于 “距离 X 在 $[0, R]$ 上均匀”。半径越大的环带面积越大, 因此 $F_X(x)$ 是二次函数而不是 x/R 。

1.5.4 Review

1. 两个独立事件取补后仍独立; 三个及以上事件必须区分 pairwise independence 与 mutual independence。

2. 随机变量是函数 $X : S \rightarrow \mathbb{R}$ ，它把原始结果转换为可分析的数值。
3. 随机变量事件的概率由其在样本空间中的原像决定。
4. CDF $F_X(x) = P(X \leq x)$ 在整个实数轴上定义，并且右连续。
5. 离散分布中，CDF 的跳跃大小恰好等于对应点的概率质量。